Introduction to Artificial Intelligence

Topic 2a: Machine Learning

Stefaan Haspeslagh
Andy Louwyck

Overview

- Machine Learning ≠ Artificial Intelligence
- Machine Learning ⊂ Artificial Intelligence

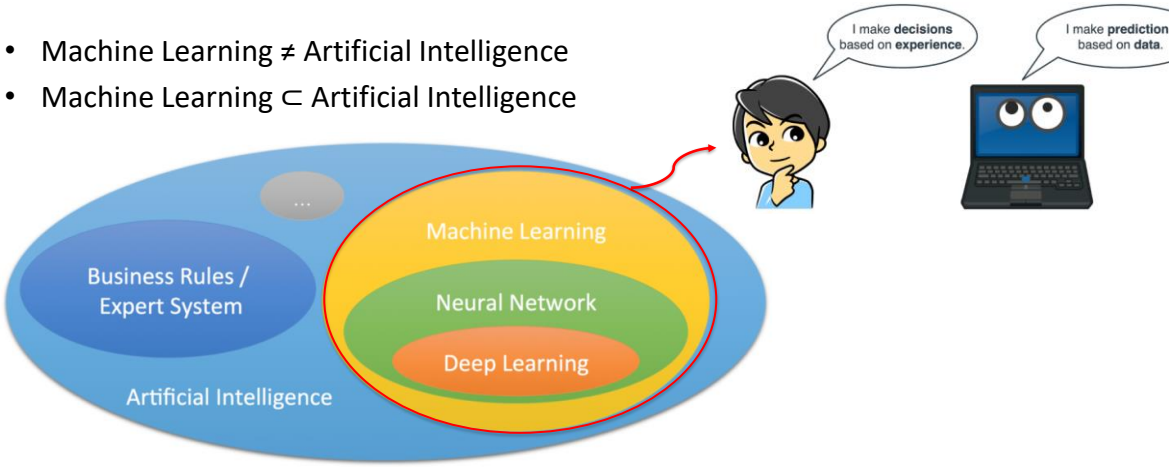

- Machine Learning = common sense, except done by a computer

De overzichtsfiguur met de verzamelingen komt uit de vorige les en laat duidelijk zien dat AI en ML geen synoniemen zijn, ook al worden beide begrippen vandaag de dag dikwijls in één adem vernoemd. Binnen AI zijn er namelijk verschillende stromingen, scholen of onderzoeksvelden, waarvan ML er één van is. In het Nederlands spreken we van machinaal of automatisch leren (https://nl.wikipedia.org/wiki/Machinaal_leren).

In ML worden algoritmes ontwikkeld, bestudeerd en toegepast die zichzelf gaan verbeteren door ervaring. Dat verbeteren door ervaring noemen we “leren”. Net als bij mensen dus. Als we bijvoorbeeld een nieuwe computer willen kopen, dan is onze uiteindelijke keuze gebaseerd op eerdere ervaringen, van onszelf of van andere mensen. Wij nemen beslissingen op basis van ervaring, die we via trial-and-error hebben opgedaan. We proberen dingen uit, maken hierbij foutjes, maar leren uit die fouten zodat we het de volgende keer beter doen.

In ML gaan algoritmes eveneens trial-and-error toepassen om zichtzelf te verbeteren in het uitvoeren van specifieke taken. In veel van die taken moet een computer voorspellen of bepaalde data tot een bepaalde categorie behoren. Denk aan een spamfilter. In dat geval moet het achterliggende algoritme voorspellen of een nieuwe mail al dan niet gewenst is. En hoe weet het algoritme dat? Wel, doordat het geleerd heeft uit eerdere mails. M.a.w. het heeft ervaring opgedaan uit die eerdere mails. “Data” is in ML dus een ander woord voor “ervaring”. In die zin zouden we kunnen

zeggen dat ML niet meer of minder is dan “gezond verstand toegepast door een computer”.

AI zouden we kunnen definiëren als alle computertaken waarin de computer zelf beslissingen neemt, en ML is dan de tak binnen AI waarin een computer gebruik maakt van data om die beslissingen te nemen (zie het boek Grokking Machine Learning v12 van Luis G Serrano). ML zorgt er bovendien voor dat een computer zichzelf kan verbeteren, kan “leren”, zodat het steeds beter wordt in het nemen van die beslissingen.

Dat “leren” is ook één van de grote verschillen met die andere grote stroming binnen AI, de expert systems, die in de jaren 70 opmars maakten en in de jaren 80 een hoogtepunt kenden. In plaats van algoritmes te voeden met regels, voeden we ze met data en laten we ze zelf regels formuleren die zo goed mogelijk de data weergeven.

Tenslotte zie je op de figuur ook nog neurale netwerken en deep learning staan. Beiden zijn een onderdeel van ML, en zijn in feite ook de reden waarom ML vandaag de dag zo succesvol en dus ook zo populair is. Maar ook hier is het zo dat ML niet louter en alleen het toepassen van neurale netwerken is. Het verschil tussen neurale netwerken en deep learning is in feite arbitrair. Andrew Ng, een bekende onderzoeker binnen ML, stelt dat DL gewoon een fancier naam is voor neurale netwerken. Andere onderzoekers spreken van deep learning wanneer neurale netwerken van minstens 3 lagen worden toegepast, om zo een onderscheid te maken met de allereerste neurale netwerken die hoogstens twee lagen hadden.

Overview

Data science ≠ Machine Learning

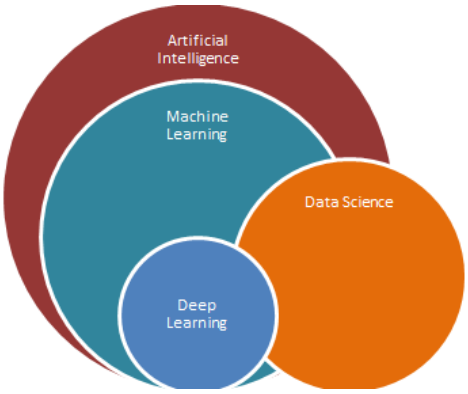

In practice:

- ML team: delivers software
- DS team: provides new insights

Wanneer we dus over ML spreken, dan spreken we ook over data, in de meeste gevallen veel data, big data dus. En dan stelt zich de vraag: wat is het verschil met data science?

Ook hier is er weer discussie tussen experten, maar feit is dat DS methodes uit ML gebruikt. DS gebruikt ook andere methodes, waarvan sommige nog als AI kunnen bestempeld worden, andere zijn dan louter statistische methodes en behoren niet tot AI. Vandaar dat men vaak de verhouding tussen AI, ML en DS weergeeft zoals op de figuur. Er is overlap tussen DS enerzijds en AI en ML anderzijds, maar DS hoort niet volledig tot AI of ML.

ML heeft meestal software als resultaat, een algoritme of een combinatie van algoritmes die ergens worden ingebouwd. Denk opnieuw aan de spamfilter in je mailapplicatie. Een team van ML developers en engineers ontwikkelen dus software die automatisch informatie haalt uit grote hoeveelheden data.

DS heeft meestal nieuwe inzichten als resultaat, inzichten waarmee een bedrijf, een organisatie of een overheidsinstelling aan de slag kan om een bepaald beleid te verbeteren. Denk hierbij aan klantenbeleid, personeelsbeleid, financieel beleid of milieubeleid. Een team van data scientists gaat ook informatie uit vaak grote hoeveelheden data halen, maar bundelt die informatie in rapporten of presentaties tot interessante inzichten die dan worden gecommuniceerd met de beleidsmakers

binnen een bedrijf of organisatie.

(Uit: “AI for everyone van Andrew Ng - https://www.coursera.org/learn/ai-for-everyone)

Artificial Intelligence: introduction and examples

MACHINE LEARNING

In deze les gaan we het dus hebben over Machine Learning. Het doel van de les is
- om te verduidelijken wat Machine Learning is,
- om veel gebruikte termen te verduidelijken,
- en om enkele vaak toegepaste algoritmes eenvoudig uit te leggen.
- En uiteraard gaan we ook voorbeelden geven en bespreken van ML toepassingen.

De meeste slides komen uit de lessen van prof. Celine Vens en prof. Hendrik Blockeel (Computerwetenschappen, KUL).
Sommige slides komen uit het inleidende hoofdstuk van het boek “grokking Machine Learning (v12)” van Luis G Serrano.
Dit handboek wordt gebruikt in de lessen van het vak Machine Learning Fundamentals.

Machine learning

- We are drowning in data but starving for knowledge [Naisbitt, 1982]
  - A lot of data is gathered, but never used
  - It is easier to generate data than to analyse it

Zoals in de vorige slides uitgelegd zijn data zeer belangrijk voor ML. Data worden vaak aangeduid als de nieuwe olie, de brandstof voor AI, en dus vooral voor ML.
Vandaar ook dat er nu heel veel data worden verzameld. Maar het verzamelen van data is niet zo moeilijk, zeker vandaag de dag niet. Dé uitdaging is om al die data te gaan analyseren en interpreteren.
Het zal je dan ook niet verbazen dat er heel veel data zijn die niet gebruikt worden. Ruwe olie, zeg maar, die nog moet aangeboord worden.

Machine learning

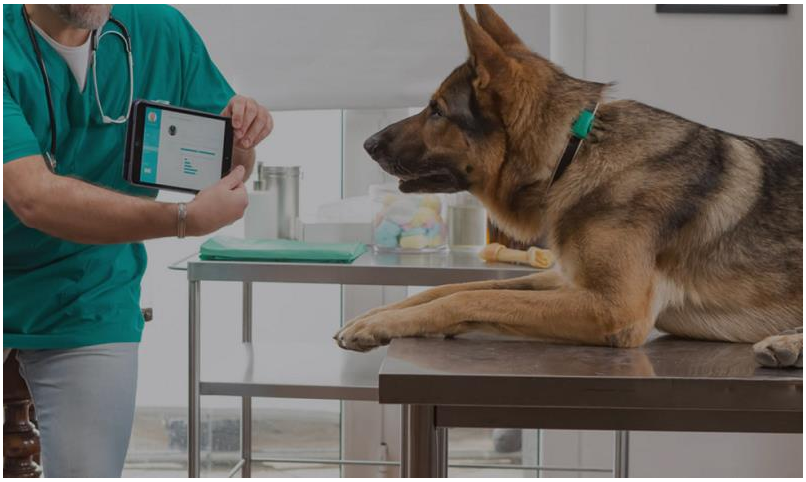

Een eerste voorbeeld om aan te tonen dat de hoeveelheid te verzamelen data gigantisch is, is de Fitbark. Een Fitbit-toestel voor honden.
De Fitbark controleert een aantal parameters zoals hartslag, hoeveelheid beweging, … Die gegevens worden doorgestuurd naar een server en geanalyseerd. Op een app kan je zien hoe “gezond” je hond is.
In het rekenvoorbeeld op de volgende slide gaan we uit van 100.000 verkochte toestellen, wat gezien het aantal honden op de wereld een realistisch en onderschat getal is.

Machine learning

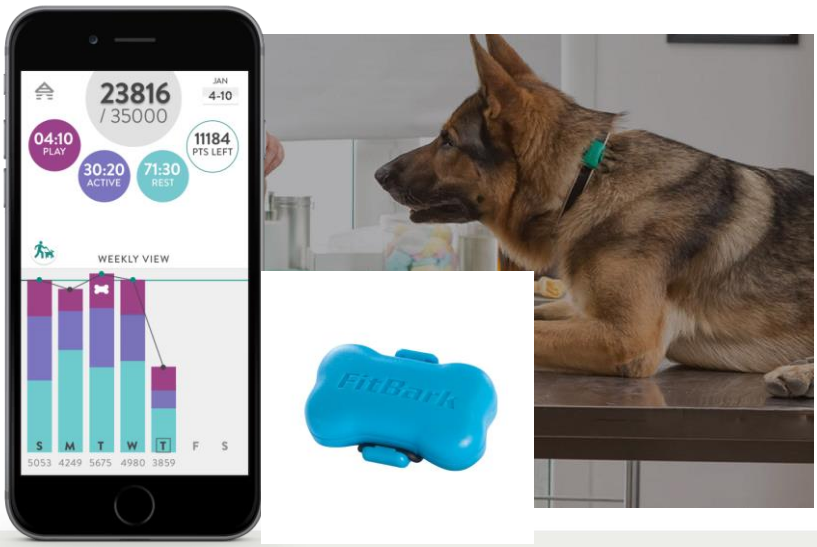

Every 5 seconds
100.000 devices
at least 100.000 messages every 5 seconds
1 kB / message → 100 MB every 5 seconds
1 minute: 1.200.000 messages → 1200 MB = 1,2 GB
1 hour: 72 GB
1 day: 1728 GB = 1,728 TB per day!

We zien dus dat voor slechts 100.000 toestellen de hoeveelheid te verwerken gegevens op een dag gigantisch is. We hopen met machine learning dergelijke gegevensverzamelingen te kunnen analyseren.

Machine learning

- Core domain of AI, concerned with automatic learning

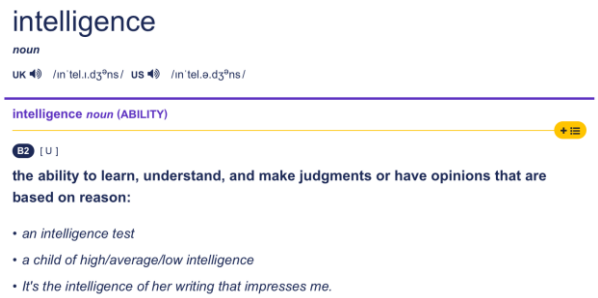

- A computer is said to be able to learn if its performance in solving some task improves with its experience

Zoals we al in de eerste slide hebben uitgelegd, onderscheiden Machine Learning technieken zich van andere AI-technieken omdat de performantie van het model verbetert naargelang het model meer taken ”oplost”.
Dit kan het volgende betekenen:

- Op volgende taken kan het model “betere” beslissingen nemen
- Als het model meermaals voor eenzelfde taak een beslissing neemt, dan wordt het resultaat in de meeste gevallen steeds meer “betrouwbaar”.

We moeten wel voorzichtig zijn met het gebruikt van woorden zoals “beter” en “betrouwbaar”.
In menselijke taal is vaak al snel duidelijk wat de betekenis en connotatie van die woorden is. In computerwetenschappen moeten we hier een duidelijke betekenis afspreken.
In mindere mate in dit topic, maar zeker in het vak Machine learning proberen we daar een antwoord op te geven.

In de volgende slides zien we een aantal voorbeelden van Machine Learning (ML).

Machine learning

- *Gmail automatically helps identify spam and suspicious emails by detecting viruses, finding patterns across messages, and learning from what Gmail users like you commonly mark as spam or phishing.*

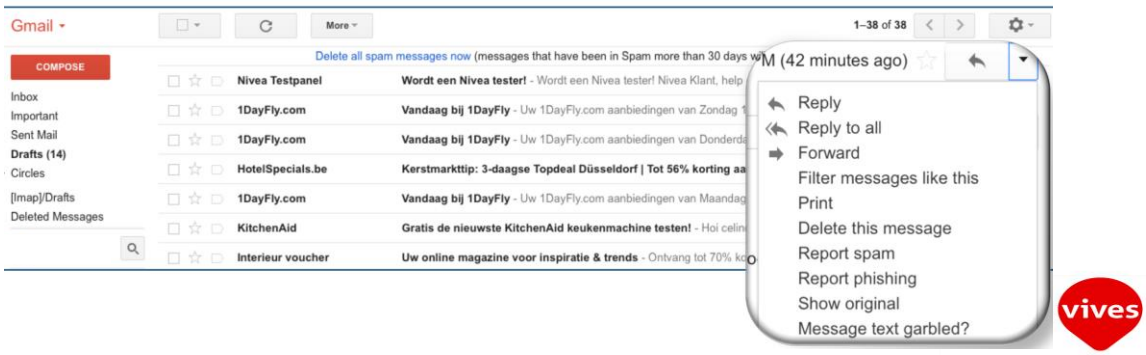

Een bekend voorbeeld zijn spam-filters, zoals we al in het begin van deze les hebben gezegd.
Op basis van het gelijktijdig voorkomen van bepaalde kernwoorden (en nog veel meer dan dat) wordt ingeschat of een bepaalde mail spam is of niet.

Machine learning

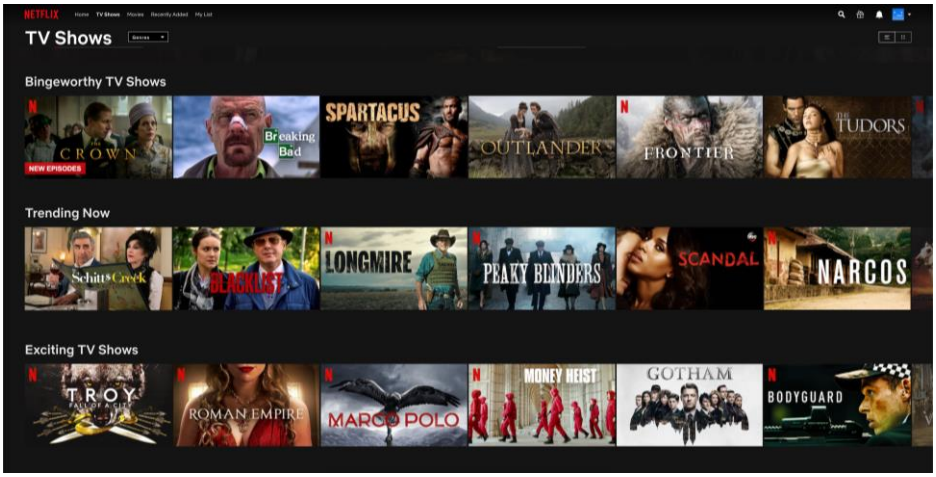

Een ander voorbeeld is Netflix of YouTube die films, series of video's aanbeveelt aan gebruikers. Die aanbevelingen zijn persoonlijk en de achterliggende algoritmes zijn ML algoritmes.
De algoritmes maken niet alleen gebruik van jouw persoonlijke voorkeuren, maar gaan ook op zoek naar gebruikers met een gelijkaardige smaak om nog beter te kunnen voorspellen welke films of video's jij leuk zal vinden.
Dit soort van systemen worden recommender systems genoemd. In het geval van Netflix wordt gebruik gemaakt van verschillende algoritmes.

(bron: https://medium.com/@springboard_ind/how-netflixs-recommendation-engine-works-bd1ee381bf81)

Machine learning

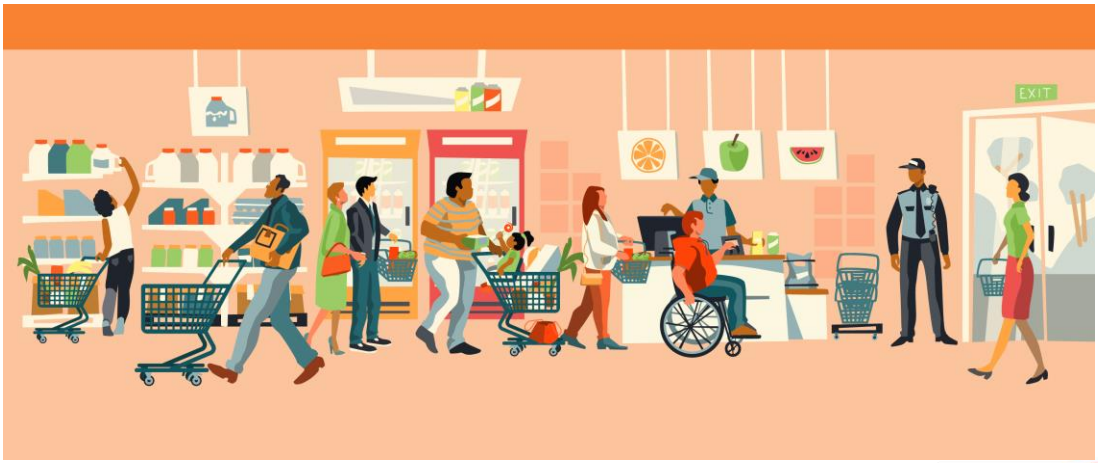

Een derde voorbeeld zijn supermarkten.
Op basis van clusteranalyse slaagt Colruyt er al meer dan tien jaar in om gepersonaliseerde reclamefolders te sturen naar hun klanten.

Heden ten dage gaat men nog verder. Men organiseert de winkelinrichting zelf op basis van verkoopsgegevens.
Producten die het vaakst samen gekocht worden wil men namelijk zo veel mogelijk verspreiden in de winkel zodat klanten de volledige winkel te doorzoeken naar hun boodschappen.
Dit verhoogt de kans dat andere producten aangekocht worden dan enkel die producten die een klant op zijn of haar boodschappenlijstje staan hebben.

Machine learning tasks

- Prediction
- Clustering
- Association rule mining
- Anomaly detection

Prediction → supervised learning → learning from (input, output) pairs

Grosso modo kunnen we ML indelen in een viertal verschillende soorten taken.

Predictie

In deze categorie bekijken we vooral data waar we al een uitkomst van weten. Die uitkomst noemen we een label, we spreken van gelabelde data.
Als we dan nieuwe data te zien krijgen, dan willen we daar een uitspraak of predictie over doen. We willen de data relateren aan één van de gekende labels.

Clustering

We willen de verschillende instanties in een dataverzameling in groepen indelen. Bijvoorbeeld om doelgroepen te vinden in salesgegevens. Per doelgroep kan dan bv. een aparte marketingstrategie uitgewerkt worden.

Association rule mining

Association rule mining wordt gebruikt om patronen in data te herkennen. Bijvoorbeeld, mensen die aperitiefdranken kopen, kopen ook chips en nootjes. Dergelijke associaties kunnen dan bijvoorbeeld weer voor marketingdoeleinden gebruikt worden.

Anomaly detection

Dit is bijvoorbeeld het detecteren van fraude, verdachte transacties in bankverrichtingen herkennen, …
(Een anomalie is een afwijking, een onregelmatigheid, een uitzondering op de regel)

In het verdere verloop van dit topic gaan we iets dieper in op prediction, en dan meer bepaald bekijken we vooral supervised learning. En we bespreken ook kort clustering, wat unsupervised learning is. Association rule mining is trouwens ook een vorm van unsupervised learning, en anomaly detection meestal ook.

Machine learning types

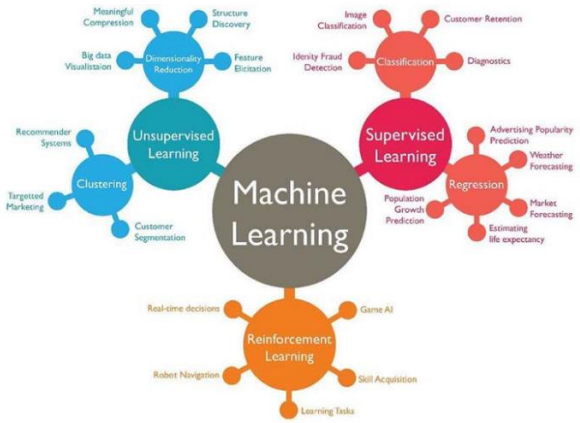

Category of machine learning. Image by https://www.techleer.com/articles/203-machine-learning-algorithm-backbone-of-emerging-technologies/

Een andere indeling die je vaak tegenkomt is diegene die je op deze slide ziet. Daar worden 3 grote families onderscheiden:

- Supervised learning (gecontroleerd leren): hieronder vallen algoritmes die gebruik maken van gelabelde data.

De twee belangrijkste toepassingen van supervised learning zijn regressie en classificatie. Bij regressie zijn de te voorspellen data numeriek (continu), bij classificatie zijn ze categorisch (discreet).

- Unsupervised learning (ongecontroleerd leren): deze algoritmes maken gebruik van data die niet gelabeld zijn. De belangrijkste toepassing is clustering.

Hierbij gaat men data in groepen of clusters opdelen obv gelijkenissen tussen de data.

- Reinforcement learning (ondersteund leren): het algoritme verzamelt zelf data via simulaties waarin een software agent acties uitvoert in een omgeving om een bepaald doel te bereiken.

Bij elke actie krijgt de agent een beloning (reward) waardoor hij leert om na verloop van tijd betere acties te nemen zodat het doel wordt bereikt met een maximale totale beloning.
De omgeving kan bijvoorbeeld een doolhof zijn waarin een agent de uitgang moet zien te bereiken.

Dit zijn de 3 belangrijkste types van ML, maar er zijn nog andere, zoals semi-supervised learning, deep reinforcement learning, active learning, inductive, deductive en transductive learning.

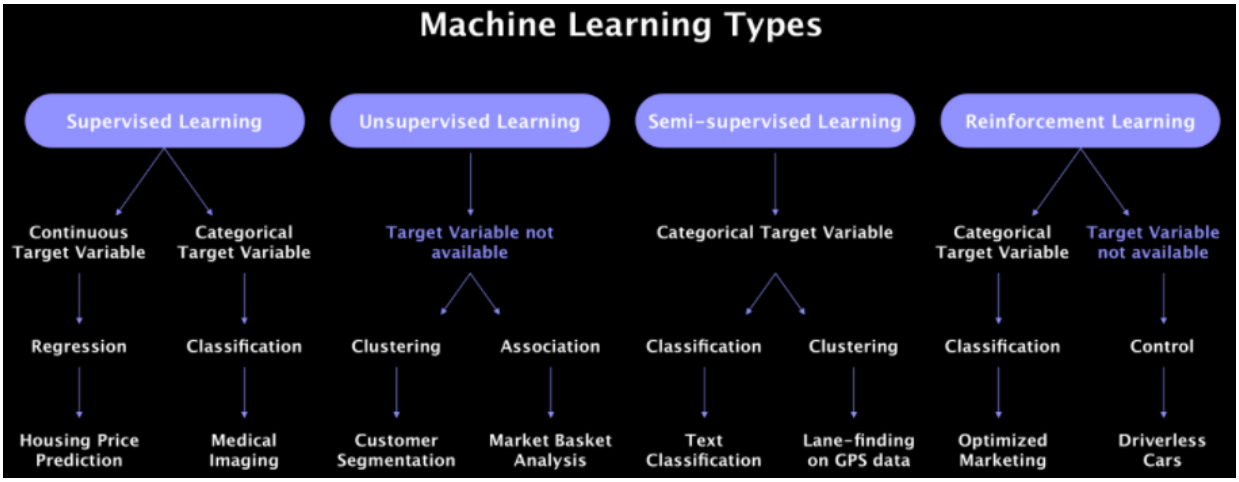

source: https://towardsdatascience.com/types-of-machine-learning-algorithms-you-should-know-953a08248861

In deze slide zien we de verschillende types en subtypes van ML weergegeven in een boomstructuur, met onderaan telkens een voorbeeld van elk (sub)type.

Lane finding algoritmes bijvoorbeeld zoeken rijstroken in GPS data en zijn uiteraard belangrijk bij zelfrijdende auto's.

Machine learning: data

- Data = information, e.g table
- Example = row in table
- Feature = column in table
- Label = feature we are trying to predict

data(set)

	A	B	C	D	E	F
1	id	datum	gewenst	grootte	tikfouten	ontvangers
2	0	12/01/2021	ja	2.5	0	1
3	1	13/01/2021	ja	1.3	0	2
4	2	14/01/2021	nee	12.1	3	15
5	3	15/01/2021	nee	7.8	2	19
6	4	16/01/2021	ja	4.6	1	5
7	5	17/01/2021	nee	9.8	5	1
8	6	18/01/2021	nee	11.6	3	63

example

label feature

Het verschil tussen supervised en unsupervised learning is dus dat de eerste type algoritmes gebruik maken van gelabelde data, en de tweede van niet-gelabelde data. Maar wat betekent dat?

Stel dat je een dataset hebt met mailgegevens. Die kunnen we als een tabel opslaan, bijv in Excel. Elke mail krijgt een id. Verder hebben we ook de datum waarop de mail is verstuurd, de grootte van de mail in kB, het aantal tikfouten in de mail en het aantal ontvangers. Tenslotte krijgt elke mail ook een label die aangeeft of de mail gewenst of ongewenst is.

Elke mail komt overeen met een rij in de tabel. Dit noemen we een instance of example. De verschillende kolommen zijn de features, en de feature die we proberen te voorspellen, in dit geval de kolom gewenst, is dus het label.

Machine learning: data

- **Labeled data**: data with label
  → **SUPERVISED** LEARNING

- **Unlabeled data**: data without label
  → **UNSUPERVISED** LEARNING

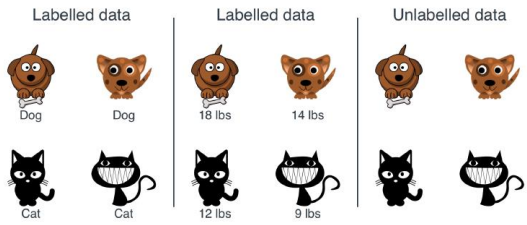

Bij supervised learning hebben de examples in de dataset altijd een label; bij unsupervised learning niet.

De eerste twee groepen met images van katten en honden zijn dus gelabeld, de derde groep niet.

(bron: grokking Machine Learning v12 van Luis G Serrano)

Machine learning: data

- **Categorical data** (nominal or ordinal) ➔ **classification**
- **Numerical data** (interval or ratio) ➔ **regression**

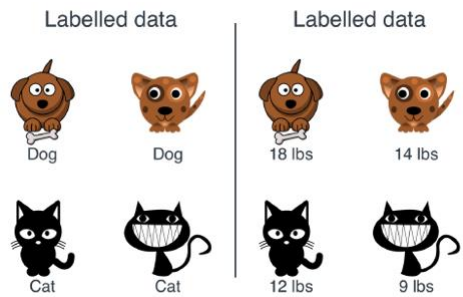

Categorical **Numerical**

Kijken we nu eens naar de twee groepen van gelabelde data, dan zien we dat in het eerste geval de te voorspellen data categorisch of kwalitatief zijn, omdat ze naar een categorie of een klasse verwijzen, nl. kat of hond.
In de tweede groep hebben we kwantitatieve of numerieke data, namelijk het gewicht in pond.

Categorische data kunnen nominaal of ordinaal zijn. In het laatste geval kan je de data ordenen. Denk bijvoorbeeld aan de resultaten van een examen uitgedrukt in letters A, B, C en D.

Numerieke data kunnen gemeten zijn op een interval- of een ratioschaal. In beide gevallen kan je de data bij elkaar optellen of van elkaar aftrekken, maar enkel in het laatste geval is het zinvol om de data te vermenigvuldigen of te delen omdat er dan een absoluut nulpunt is.

Het meetniveau van temperaturen gemeten in graden Celsius is “interval”. Het heeft daarom geen zin om te zeggen dat het vandaag 2 keer kouder was dan gisteren.
Het meetniveau van lichaamslengten in meter is “ratio”. Lengte heeft idd een absoluut nulpunt, en dus is het wel zinvol om te zeggen dat een persoon anderhalf keer groter is dan een andere persoon.

Wanneer men in supervised learning te maken heeft met categorische data, dan

spreekt men van classificatie. Gaat het om numerieke data, dan noemt men het regressie.

(bron: grokking Machine Learning v12 van Luis G Serrano)

Machine learning: algorithm and model

- **Model**: A set of rules that represent our data and can be used to make predictions.
- **Algoritme**: A procedure, or a set of steps, used to build a model.

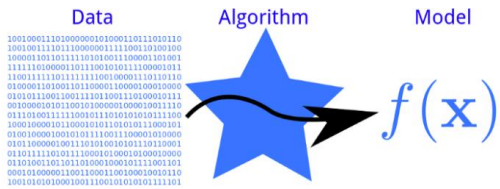

An algorithm is run on data to create a model

Twee andere belangrijke termen zijn algoritme en model. Heel vaak worden deze twee termen door elkaar gebruikt, ook al zijn ze niet hetzelfde.
ML past algoritmes toe die uit de data (beslissings)regels afleiden. Deze regels noemen we een model. (bron: grokking Machine Learning v12 van Luis G Serrano).
In ML is dat een wiskundig of statistisch model. Dat model krijgt de data als input, en mbv allerhande wiskundige bewerkingen zet het die input om naar de gevraagde voorspellingen, die dus de output van het model zijn.

Machine learning: algorithm and model

Example: linear regression

- **Input**: (x, y) data with x = height (inches) and y = weight (pounds)
- **Output**: predicted weight
- **Algorithm**: calculates the best fitting line

  find parameters m and b in

  $$y = mx + b$$

- **Model**: the best fitting line

  $$\text{weight} = -222.5 + 5.49 \text{ height}$$

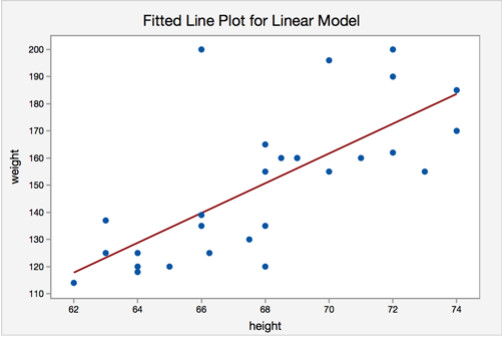

Neem bijvoorbeeld een eenvoudige lineaire regressie die het verband vastlegt tussen lichaamslengte en lichaamsgewicht van personen. M.a.w., we willen het gewicht van een persoon voorspellen obv zijn/haar lichaamslengte.
De input zijn de data, in dit geval de lengte en het gewicht van verschillende personen. De output van het model zijn de berekende gewichten. Het algoritme is de code die de vergelijking van de best passende rechte afleidt. Een rechte wordt gekarakteriseerd door twee parameters: de rico m en de intercept b. Het algoritme gaat op zoek gaan naar de waarden van deze twee parameters zodat de berekende output, de y-waarden volgens de vergelijking van de rechte, het minst afwijkt van de gegeven y-waarden. Het model is de vergelijking van de best passende rechte, dus de vergelijking waarin de waarden van de rico en de intercept ingevuld zijn. Met deze best passende rechte kunnen we dan voorspellen hoeveel een persoon met een gegeven lengte zal wegen. (voorbeeld komt van https://online.stat.psu.edu/stat500/book/export/html/478)

Machine learning: algorithm and model

Example: artificial neural network

- **Input**: labeled images
- **Output**: predicted labels
- **Algorithm:**
  backpropagation + an optimizer
  to find weights that minimize loss
- **Model**:
  neural network with optimal weights

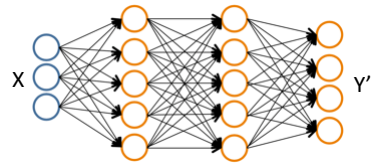

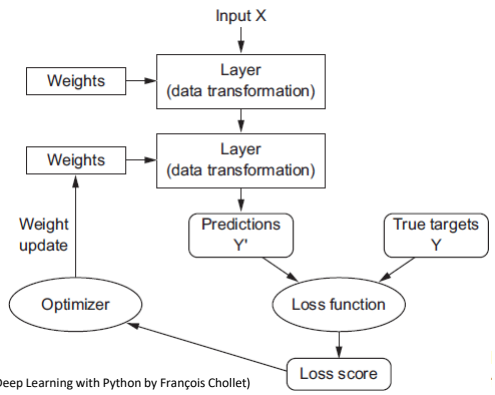

(Source: Deep Learning with Python by François Chollet)

Bij een neuraal netwerk dat images met katten en honden moet gaan classificeren bestaat de input uit alle images die gelabeld zijn met kat of hond. De output zijn de labels die het neuraal netwerk heeft berekend. De loss functie berekent een score obv het verschil tussen de echte labels en de voorspelde labels. De bedoeling is dat deze loss score zo klein mogelijk is.

Het neuraal netwerk bestaat uit heel veel neuronen die net als in echte hersenen met elkaar zijn verbonden. Meestal zijn die neuronen in verschillende lagen gestructureerd. De inputdata, in dit geval de images, worden via de verbindingen tussen de neuronen van de ene laag naar de andere doorgegeven, en in elk neuron worden de data getransformeerd dmv een wiskundige functie. Elke verbinding tussen twee neuronen krijgt een gewicht dat net als in echte hersenen de sterkte van die verbinding bepaalt.

Deze gewichten zijn de parameters die moeten geoptimaliseerd worden aan de hand van de data, net als bij de lineaire regressie. Dat optimaliseren gebeurt door het backpropagationalgoritme en een optimalisatiealgoritme. Maar omdat er hier heel veel parameters zijn, gebeurt dat iteratief: de gewichten worden stap voor stap aangepast adhv de berekende loss score. Er worden meestal heel veel iteraties doorlopen tot er een loss score uitkomt die voldoende klein is.

Het zoeken van de optimale gewichten noemt men trainen. Het resultaat van dat

trainen is het neuraal netwerk met geoptimaliseerde parameters, d.w.z. de parameters die de meeste labels van onze inputdata juist voorspellen. Dat neuraal netwerk met geoptimaliseerde parameters is het model. Obv dat model kan men dan nieuwe images van katten en honden gaan classificeren.

Naast classificatie, kunnen we op dezelfde manier regressies uitvoeren. Zo kunnen we zelfs de eenvoudige lineaire regressie uit de vorige slide met een neuraal netwerk met slechts één neuron oplossen.
Neurale netwerken kunnen naast supervised learning ook unsupervised learning aan.

ML: supervised learning

- Task: learn a model to predict a property (target) for new data instances, based on training set of data instances for which the property is observed

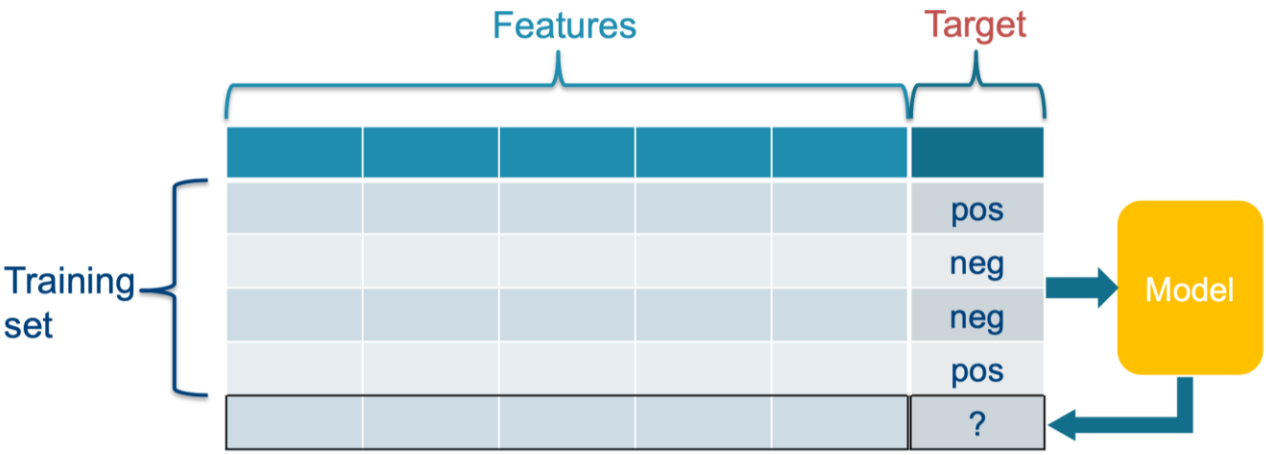

Nu we vertrouwd zijn met de ML terminologie, kunnen we de algemene structuur van supervised learning problemen als volgt samenvatten.

We stellen opnieuw de gegevens in een Excel-tabel voor. De kolommen zijn dus de kenmerken of de features van de data; de rijen de verschillende 'instanties' of voorbeelden.
Eén van de kolommen bevat de labels, wat men de target of het doel noemt. Dit is de uitkomst die of het resultaat dat moet voorspeld worden.

Als voorbeeld kunnen we het verkopen van huizen nemen. De kolommen zijn dan bijvoorbeeld:
- De oppervlakte van de grond
- Het aantal slaapkamers
- Open bebouwing, half open of gesloten
- Bewoonbare oppervlakte
- …

Per rij in het "Excel"-blad heb je dan een huis dat verkocht werd, waar telkens de kolommen ingevuld werden. De target kolom is bijvoorbeeld de prijs.

Doel van supervised learning is om op basis van die gegevens een model te maken. Dat model moet dan in staat zijn om voor een "nieuwe rij data", waar het target nog

niet voor gekend is, een behoorlijke waarde voor dat target te voorspellen. In ons voorbeeld willen we dus voor een nieuw te verkopen huis de vraagprijs of verkoopprijs gaan schatten. Omdat prijzen van huizen numeriek zijn, hebben we hiervoor een regressiemodel nodig.

Binnen predictie en supervised learning kan je de mogelijke problemen en taken als volgt opdelen:

<u>Classificatie</u>

Zoals we al gezegd hebben gaat classificatie over het voorspellen van categorische data. Een bekend voorbeeld is het herkennen van een kat of een hond op een foto. Het systeem krijgt een behoorlijk aantal foto's te zien waarop een kat ofwel een hond staat. Van die foto's is het systeem op de hoogte van de uitkomst. Doel is om voor een nieuwe foto te beslissen of er een kat of een hond op staat. Dit is een voorbeeld van binaire classificatie: er zijn slechts twee mogelijke uitkomsten.
Er bestaan ook multi-class classificatiesystemen: bv. het herkennen van voertuigen op een foto, waar het onderscheid moet gemaakt worden tussen auto's, fietsen, vrachtwagens, …

<u>Regressie</u>

Bij regressie is de uitkomst meestal een getal, zoals we al hebben uitgelegd. Denk maar aan het voorspellen van verkoopsprijzen van huizen. Daar zijn er niet een vast aantal mogelijke prijzen bv 50.000 en 100.000, maar is elke mogelijke verkoopsprijs tussen die getallen ook een optie.

Classificatie en regressie zijn de belangrijkste taken, maar er zijn nog andere:

Time-to-event prediction

Hier wordt een tijdstip voorspeld waarop een gebeurtenis mogelijk kan voorkomen. Bv. wanneer is er onderhoud nodig aan een machine, wanneer moet ik communiceren met een klant voordat hij afhaakt, wanneer zal een persoon met bepaalde symptomen een bepaalde complicatie krijgen of een bepaalde ziekte ontwikkelen?

Learning to rank

Hier worden een volgorde voorspeld. Welke film zou een kijken als best ervaren? Welke film komt op de tweede plaats, … Hier is enkel volgorde belangrijk, niet "hoe goed een film is". Je kan het vergelijken met het verkopen van huizen waar je enkel de huizen rangschikt volgens verkoopsprijs (wat is de duurste woning, wat de goedkoopste) zonder de exacte verkoopsprijs te kennen.

Link predictie

Hier probeert men te voorspellen of er een link is tussen twee (of meerdere) entiteiten in een netwerk. Denk maar aan sociale media, zoals Facebook, waar met probeert te voorspellen wat interessante 'vriendschappen' kunnen zijn.

Multi-outputprediction

Dit combineert de vorige 5 types problemen.

ML: unsupervised learning

Example: clustering

No labels!

E-mail	Size	Recipients
1	8	1
2	12	1
3	43	1
4	10	2
5	40	2
6	25	5
7	23	6
8	28	6
9	26	7

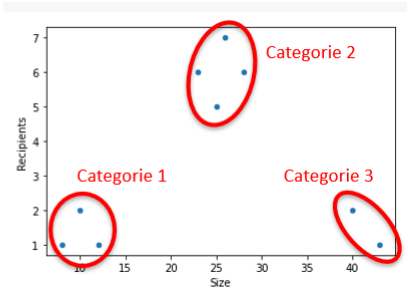

Wanneer we het over unsupervised learning hebben, dan denken we in de eerste plaats aan clustering.
Hier is het de bedoeling om data zonder labels op te delen in groepen of clusters.
Links zie je een tabel met mail-gegevens. Rechts werden de kolommen “size” en “recipients” tegen over elkaar uitgezet in een grafiek.
In de grafiek valt direct op dat er drie categorieën of clusters zijn. Op basis hiervan zouden we dan kunnen beslissen om de mails in categorie 1 als gewenst te labelen, en de mails uit de andere categorieën als spam.
Op die manier kunnen we onze mailgegevens labelen en zijn ze bruikbaar om een supervised learning algoritme te trainen.

ML: unsupervised learning

- **Classification**: labeled data → classes already exist
- **Clustering**: unlabeled data → classes don't exist yet

customer	age	salary	risk
0	23	1500	high
1	51	2500	low
2	42	3100	low
3	36	1900	high
4	67	2100	low

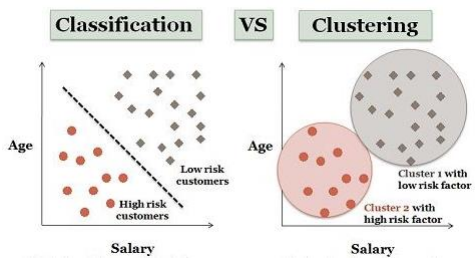

customer	age	salary	risk
0	23	1500	?
1	51	2500	?
2	42	3100	?
3	36	1900	?
4	67	2100	?

(source: https://techdifferences.com/difference-between-classification-and-clustering.html)

Clustering lijkt heel erg op classificatie, maar het is belangrijk om in te zien dat bij clustering de klassen nog niet bestaan, terwijl ze bij classificatie wel al bestaan, omdat de labels de klassen bepalen.
In het voorbeeldje heb je een dataset met klanten van wie oa leeftijd en salaris is gekend.

Bij classificatie hebben bestaande klanten ook al een label gekregen en zijn ze dus al opgedeeld in een lage en een hoge risico groep.
Obv een supervised learning model kan dan voorspeld worden of een nieuwe klant laag of hoog risico loopt.

Bij clustering is dat label niet aanwezig en zal het algoritme zelf de labels bepalen, en dat voor alle klanten.

(image: https://techdifferences.com/difference-between-classification-and-clustering.html)

ML: unsupervised learning

- K-means clustering
  https://youtu.be/nXY6PxAaOk0
- Hierarchical clustering (dendrogram)
- Gaussian mixture models
- DBSCAN

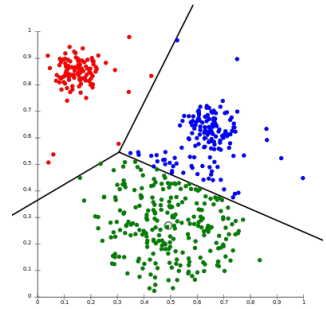

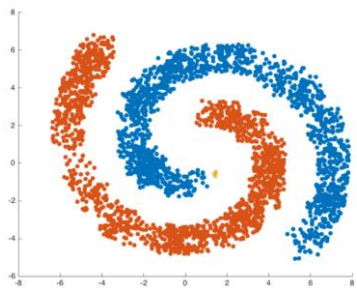

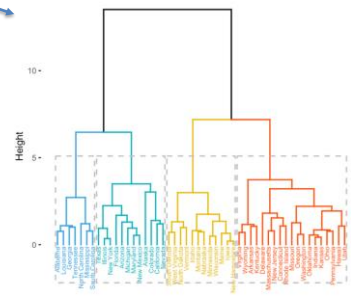

Op deze slide worden enkele voorbeelden gegeven van clustering algoritmes.

Het youtube filmpje is bijvoorbeeld een mooie visualisatie van hoe k-means clustering werkt. In ons voorbeeld van de mails konden we de groepen mooi visueel gaan afbakenen. Maar soms zijn de groepen niet zo duidelijk.
K-means clustering is een algoritme die de clustering automatisch kan uitvoeren. We moeten enkel het aantal groepen opgeven dat we willen, in ons voorbeeld 3, en dan gaat het algoritme 3 willekeurige punten op de grafiek plaatsen, zogenaamde centroïds. Daarna wordt voor elk datapunt de afstand tot de centroids berekend, en het datapunt wordt toegekend aan de cluster van de centroïd waar het het dichtst bij ligt. Dan wordt de positie van de centroïds opnieuw berekent zodat die centraal komen te liggen in de eigen cluster. Deze stappen worden herhaald tot de centroïds niet meer bewegen en alle datapunten definitief aan een cluster zijn toegekend.

We gaan hier niet dieper ingaan op deze algoritmes, maar de geïnteresseerde student kan natuurlijk altijd op internet de nodige informatie vinden.

Artificial Intelligence: introduction and examples

SUPERVISED LEARNING MODELS AND THEIR LEARNING ALGORITHMS

Supervised learning is mss wel het belangrijkste type ML. Laten we daarom eens een kijkje nemen welke andere methodes er nog bestaan binnen deze ML familie.

Machine learning: supervised learning

- There exist plenty of languages to express a model
- Each language has its bias and degree of interpretability
- No free lunch: There is no model (classifier) that works best for every problem

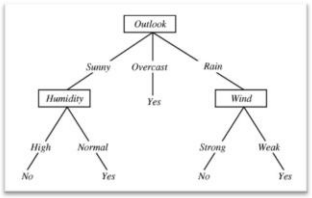

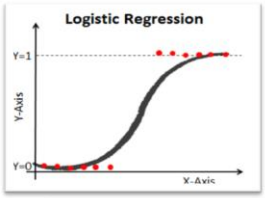

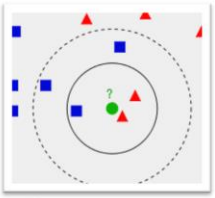

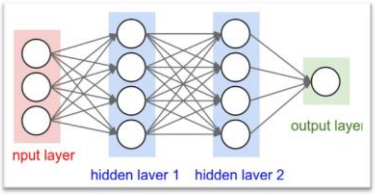

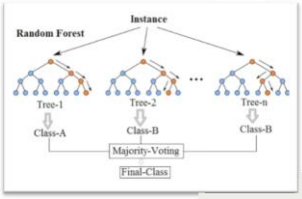

...

Per type taak of probleem (zie vorige slides) dat moet aangepakt worden, kunnen verschillende algoritmes en modellen ingezet worden.
Nemen we als voorbeeld classificatie. Veel gebruikte modellen hiervoor zijn, in volgorde zoals ze op de slide voorkomen:

- Beslissingsbomen (decision trees)
- Logistische regressie (Pas op! Dit is classificatie, geen regressie!)
- K-nearest neighbours
- Neurale netwerken
- Decision tree forests / random forests
- …

Het zal dus de kunst zijn om een bepaald probleem ‘goed’ op te lossen door een algoritme te kiezen dat tot het meest geschikte model leidt.
Helaas is die keuze niet voor de hand liggend. Twee criteria die een belangrijke rol spelen bij deze keuze zijn interpreteerbaarheid van een model, en het “no free lunch”-theorem.

<u>Interpreteerbaarheid</u>

De interpreteerbaarheid van een model is de mate waarin door mensen kan verklaard worden hoe een model tot een beslissing komt. Een beslissingsboom heeft een grote graad van interpreteerbaarheid. Bij een beslissingsboom staat elk kenmerk

die de beslissing stuurt in een knoop (rechthoeken in de boom), bij iedere tak staat een mogelijke waarde van dat kenmerk. Onderaan de boom staat dan de uiteindelijke beslissing. In het voorbeeld op de slide is dit: als het zonnig is en niet vochtig, dan is het weer goed om buiten te sporten. Welk kenmerk op welk niveau van de boom staat, dat maakt onderdeel uit van het machine learning model: het is het model dat dit moet bepalen aan de hand van de vele voorbeelden die het model krijgt voorgeschoteld. Verder in dit topic komt er een uitgewerkt voorbeeld omtrent deze procedure.

Een neuraal netwerk, dat bestaat uit heel veel verbindingen tussen neuronen met allerhande gewichten (getallen) tussen de neuronen, heeft dan weer een zeer lage interpreteerbaarheid. Bij zeer complexe neurale netwerken is er geen mens op deze planeet die weet hoe het neuraal netwerk tot een beslissing komt. Het is deze vaststelling die mensen zoals Kurzweil en Musk doet nadenken over doemscenario's waar machines mensen overtreffen (cfr. point of singularity in topic 1).

No free lunch

Er is geen model dat best werkt voor elk mogelijk probleem. In tegendeel, binnen eenzelfde probleem is het vaak zo dat soms een neuraal netwerk het beste resultaat geeft, soms een beslissingsboom. Vaak worden daarom (indien de rekentijd het toelaat) meerdere modellen gecombineerd (cfr. multi-output prediction) om een uiteindelijke beslissing te nemen.

Machine learning: lazy learning

- k-Nearest neighbours
- Main task: find suitable distance function

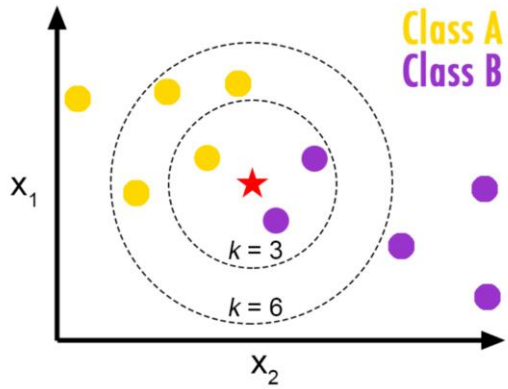

Bij k-nearest neighbours is de uitdaging om voor een nieuw datapunt (de rode ster) te beslissen, of te voorspellen, tot welke klasse de ster behoort.
De klassen zijn, in tegenstelling tot clustering bij unsupervised learning, op voorhand gekend.

Een veelgebruikte techniek is kijken 'hoe ver' het nieuwe punt ligt van andere datapunten. Hiervoor moet een juiste afstandsmaat gekozen worden (bv. Euclidische afstand).
Een tweede vraag die men moet stellen is met hoeveel punten er vergeleken wordt.

Met teveel punten vergelijken (bv. allemaal) is in grote dataverzamelingen computationeel niet interessant (niemand wil een machine learning model dat drie dagen moet rekenen om te beslissen welk weer het morgen zal zijn…) dus er moet een beperking ingesteld worden, genaamd k. De keuze voor k kan een grote invloed hebben.
Nemen we in het bovenstaande voorbeeld k = 3, dan behoort de ster tot klasse B.
Nemen we k = 6, dan behoort de ster tot klasse A.

De keuze voor k is niet eenduidig te bepalen. Hiervoor zien we in het vak machine learning een aantal technieken/beslissingscriteria.

Machine learning: regression (linear)

- Regression for numeric targets
  - Main task: estimate parameters b_0 and b_1, such that prediction and ground truth are as close as possible

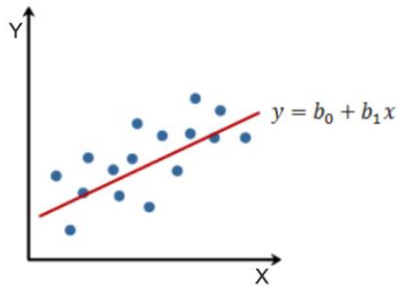

Een tweede model/techniek is regressie. Bij regressie wordt gepoogd om een rechte te vinden die de datapunten het best benaderen.
We gaan in de formule van een rechte dus op zoek naar b0 en b1, resp. intercept en rico.

Voor een nieuw datapunt wordt de formule dan eenvoudig uitgerekend: je vult de x waarde in en je krijgt een y waarde.
Dit is de voorspelde waarde (prediction), waarvan je wil dat die zo dicht mogelijk ligt bij de echte waarde (de ground truth)

Machine learning: regression (linear and non-linear)

- Linear Regression 2 features and 1 label (left)
- Non-linear regression 1 feature and 1 label (right)

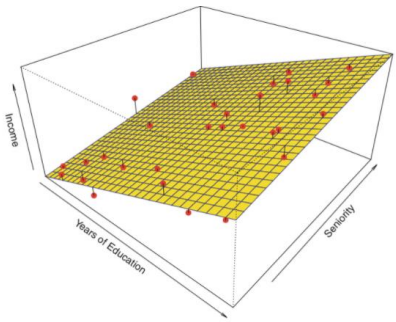

Source: James et al. *Introduction to Statistical Learning* (Springer 2013)

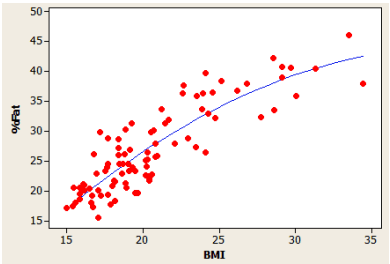

Source: the minitab blog

In de vorige slide legden we de eenvoudige lineaire regressie uit met slechts 1 feature en 1 label, maar je kan ook lineaire regressie toepassen op meerdere features.
Een lineaire regressie met 2 features en 1 label kan je voorstellen in een 3D assenstelsel, en het model is dan een best passend 2D vlak ipv een 1D rechte. Dat zie je op de linker figuur.
En naast lineaire regressie is ook niet-lineaire regressie mogelijk. In twee dimensies zoeken we dan geen best passende rechte maar een kromme. Dat zie je op de rechter figuur.

Machine learning: regression (logistic)

- Regression for binary targets

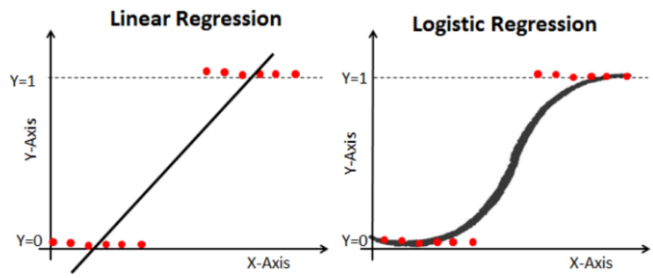

$$y = b_0 + b_1 x$$

$$p = \frac{1}{1 + e^{-(b_0 + b_1 x)}}$$

Regressie kan ook gebruikt worden voor binaire classificatie. Hiervoor wordt niet gezocht naar een rechte, maar naar een kromme die een S-vorm aanneemt. Slechts in een heel klein gebied (ongeveer in het midden op de S-curve op de figuur) is het niet onmiddellijk duidelijk tot welke klasse (Y=0 of Y=1) een nieuw punt behoort. Voor de meeste punten op de X-as is echter duidelijk wat de uiteindelijke klasse is.

Let op! De term regressie is wat verwarrend, omdat we hier een classificatieprobleem oplossen.

Machine learning: decision trees

- Decision tree and decision rule learners
  - Very popular data mining methods
  - High interpretability of models (e.g.medicine)
  - Efficient learning and prediction procedures

Een laatste techniek/model die we bekijken alvorens we neurale netwerken bespreken, zijn beslissingsbomen. Beslissingsbomen zijn van oudsher een zeer populair model binnen het domein van data mining.
Ook binnen de geneeskunde is dit een zeer populair model omwille van de hoge interpreteerbaarheid van het model.

Er bestaan heel wat efficiënte leer- en predictiemethoden om beslissingsbomen op te stellen. Er worden er een aantal gezien in het vak machine learning.

In de volgende slides leggen we iets gedetailleerder uit wat beslissingsbomen zijn en hoe een beslissingsboom kan opgebouwd worden voor eenvoudige (machine learning)problemen.

Machine learning: decision trees

- Play tennis or not? (depending on weather conditions)

Outlook	Temp.	Hum.	Wind	Play?
Sunny	85	85	False	no
Sunny	80	90	True	no
Overcast	83	86	False	yes
...	...	...	...	...

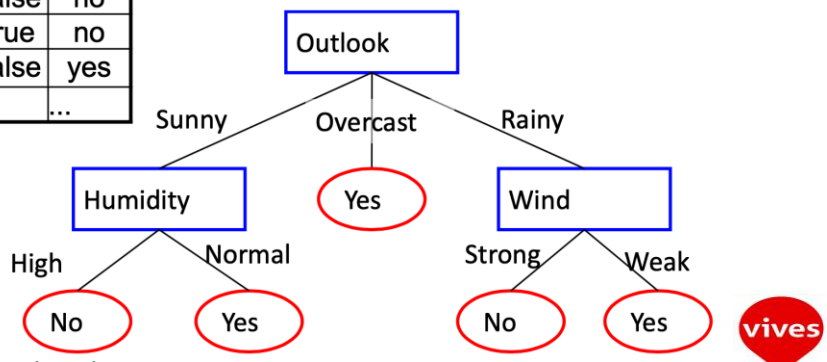

- Leaf nodes versus internal nodes

We willen een beslissingsboom opstellen om te beslissen of buiten sporten een goed idee is of niet.

Om de boom op te stellen hebben we data nodig. Er zijn een aantal voorbeelden van datapunten gegeven in de tabel.

Criteria of kenmerken die de beslissing kunnen beïnvloeden worden aangegeven in de kolommen. De laatste kolom is de target-kolom.

In de boom moet per niveau beslist worden op welk kenmerk er moet gesplitst worden. De onderste knopen in de boom bevatten de verschillende waarden van de target-kolom. In dit voorbeeld wordt een beslissingsboom gebruikt voor een binair classificatieprobleem, maar beslissingsbomen kunnen ook gebruikt worden voor multi-class beslissingsproblemen.

Door toepassing van een machine learning algoritme kan de boom van op de slide verkregen worden. Zoals je ziet hoeft niet elk kenmerk opgenomen worden in de beslissingsboom! Bepaalde kenmerken kunnen irrelevant zijn (bv. temperatuur in het voorbeeld).

Voor elk nieuw datapunt (hier een nieuwe weersituatie) kan de boom gebruikt worden om te beslissen of in te schatten of buiten sporten een goed idee is.

Bv. Is het een goed idee om buiten te sporten op een regenachtige dag, met een hoge vochtigheidsgraad en een zwakke wind.

Het eerste te beschouwen kenmerk is outlook. Het is een regenachtige dag, dus de rechtertak moet beschouwd worden. In de rechtertak is het volgende te beschouwen kenmerk de windkracht. Er staat een zwakke wind, dus weer wordt de rechtertak gekozen. Dan komen we in een blad terecht, met een voorspelde waarde voor de doelkolom, in dit geval Yes. Het is dus een goed idee om buiten te sporten voor dit voorbeeld.

Machine learning: how to learn?

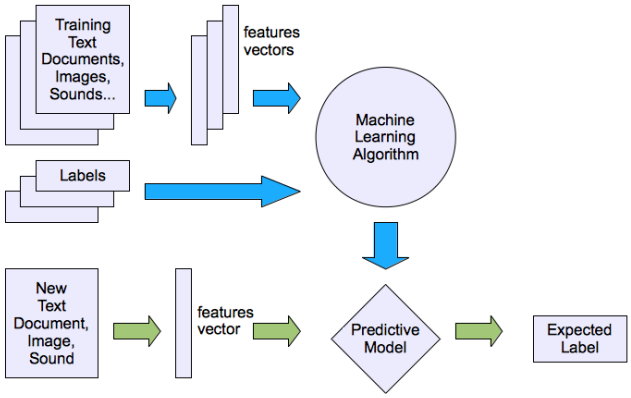

Voordat we in de volgende slides een eenvoudig machine learning algoritme toepassen om een beslissingsboom op te stellen, geven we eerst algemeen wat meer inzicht in de typische workflow die moet gevolgd worden om machine learning algoritmen en modellen toe te passen op problemen. De workflow op de slide is enkel van toepassing op supervised learning, waar we dus voldoende (input, output)-paren hebben.

Vooreerst hebben we een verzameling data, dit kunnen tekstdocumenten, Excelbestanden, figuren, geluiden, ... zijn.

Van de verschillende datapunten moeten we een aantal kenmerken identificeren. Soms is dit voor de hand liggend, in een Excelbestand zijn de kenmerken vaak de kolommen. Maar soms is die keuze minder vanzelfsprekend, bijvoorbeeld in het geval van geluid of foto's. Het samenstellen van de juiste verzameling kenmerken of features is vaak een kunst op zich.

Vervolgens kunnen we aan elk datapunt een label koppelen. Een categorie in het geval van classificatie, of een verkoopsprijs bij regressie, …

Vervolgens is het de taak van het machine learning algoritme om een predictief model op te stellen. De keuze van het algoritme bepaalt de aard van het model dat gegenereerd wordt (beslissingsbomen, neuraal netwerk, regressiemodel, …)

Het proces tot hier toe, het uitvoeren van het algoritme op data met gekende output met als resultaat het predictief model, noemt men de **trainingsfase**.

Dit predictief model kan dan gebruikt worden om voor nieuwe datapunten, op basis van dezelfde kenmerken als in de trainingfase, te voorspellen welk label er met dit datapunt moet geassocieerd worden. Deze fase is de **inferentiefase**.

Machine learning: how to learn?

- Inducing decision trees: cocktail example (example by Hendrik Blockeel)

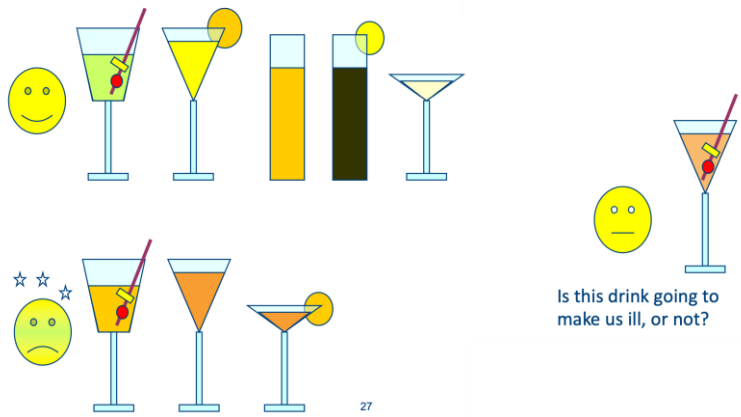

We gaan in de volgende slides een beslissingsboom opstellen voor een eenvoudig cocktail probleem.
Doel is om te voorspellen of je van een cocktail ziek wordt of niet.

We hebben natuurlijk al wat ervaring in het degusteren van cocktails.
Aan een aantal cocktails houden we goede herinneringen over. Een aantal cocktails hebben ons nachtmerries bezorgd.
Omdat we de cocktails waar we niet ziek van worden beu zijn, willen we wel eens een nieuwe cocktail proberen. Vraag is, worden we er ziek van of niet?

Machine learning: how to learn?

- Inducing decision trees: cocktail example (example by Hendrik Blockeel)

Vooreerst moeten we, met de algemene workflow voor supervised learning in ons achterhoofd, op zoek naar kenmerken die we willen gebruiken in ons predictief model.

Mogelijke kenmerken hier zijn: de vorm van het glas en de kleur van de cocktail.

Vraag is nu, welke kenmerk gebruiken we best op het hoogste niveau in onze beslissingsboom?

Machine learning: how to learn?

- Inducing decision trees: cocktail example (example by Hendrik Blockeel)

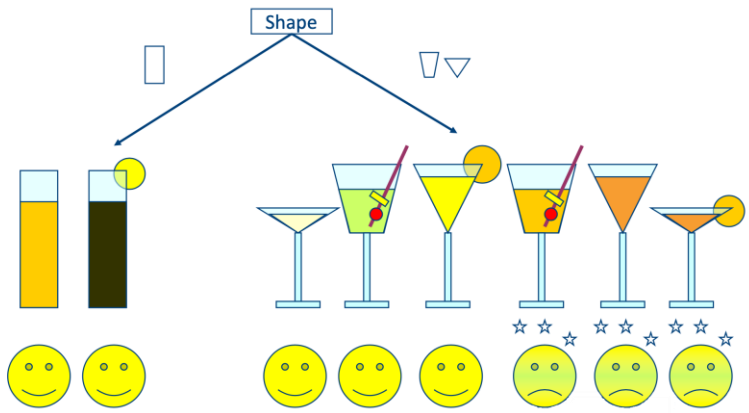

Een efficiënte boom is een beslissingsboom die niet al te diep en waar elk gebruikt kenmerk de verzameling voorbeelden in twee duidelijke deelverzamelingen opsplitst (al is dit niet altijd mogelijk!).

In dit voorbeeld is dat duidelijk de vorm van het glas. We weten dat we niet ziek worden door het drinken van **alle** cocktails die in een recht glas geserveerd worden. Dit is dus een ideaal criterium om als eerste te gebruiken. De kleur van de cocktail leidt niet tot een dergelijke duidelijke opsplitsing (ga dit zelf na!).

Machine learning: how to learn?

- Inducing decision trees: cocktail example (example by Hendrik Blockeel)

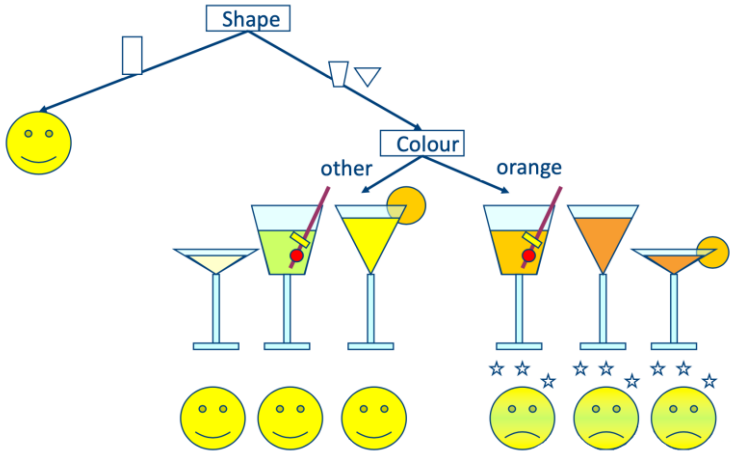

In de linkertak is dus alles duidelijk en die moeten we niet verder verfijnen.

In de rechtertak moeten we extra kenmerken gebruiken om de voorspelling te kunnen uitvoeren.

Het volgende criterium dat we gebruiken is de kleur van de cocktail. Het aantal vertakkingen willen we niet de groot maken, dus splitsen op alle mogelijke kleuren is geen goed idee. Aangezien we enkel van oranje cocktails ziek worden, kiezen we voor de opsplitsing oranje cocktail en cocktails met een andere kleur.

Machine learning: how to learn?

- Inducing decision trees: cocktail example (example by Hendrik Blockeel)

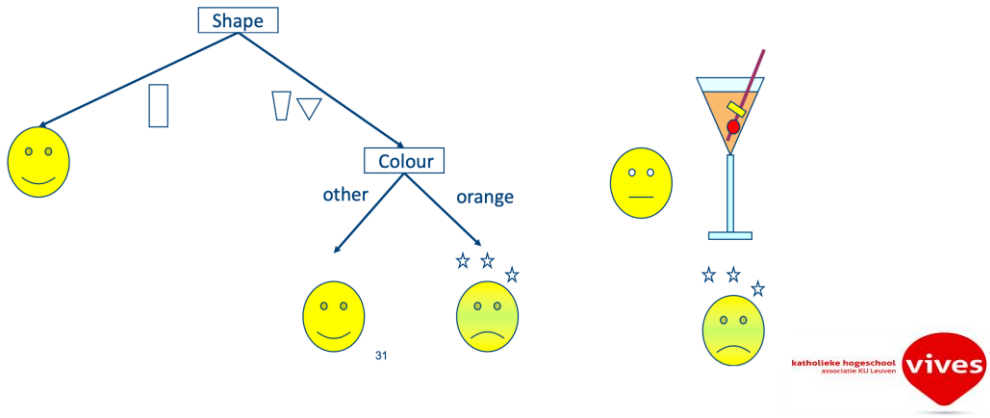

De verkregen beslissingsboom kunnen we nu gebruiken om voor de nieuwe cocktail te beslissen of we er waarschijnlijk ziek van worden of niet (het is een voorspelling, zeker kunnen we nooit zijn zonder het te proberen!!!).

Op basis van de beslissingsboom worden we mogelijks ziek van de nieuwe cocktail.

Machine learning: under- and overfitting

- Underfitting: model is too simple
- Overfitting: model is too specific

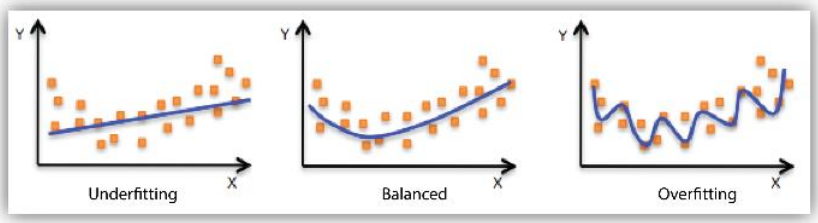

Source: https://towardsdatascience.com/underfitting-and-overfitting-in-machine-learning-and-how-to-deal-with-it-6fe4a8a49dbf

We hebben nu verschillende technieken gezien, en het kiezen van de juiste techniek om een probleem op te lossen is niet altijd eenvoudig. Maar eens we een techniek hebben gekozen, dan moeten we ook nog zien dat het af te leiden model niet te veel of te weinig parameters heeft.

Neem ons regressievoorbeeld. Stel dat het verband tussen lichaamslengte en gewicht is zoals op de figuur. Het is duidelijk dat dit geen lineair verband is omdat de puntenwolk eerder de vorm van een plat liggende banaan heeft.

Kiezen we toch om onze datapunten te fitten adhv een rechte met slechts twee parameters (links), dan krijgen we underfitting: ons model is te eenvoudig, omdat we niet alle variatie in onze dataset hebben gemodelleerd. Voorspellingen met dit model zullen niet accuraat zijn.

In de figuur rechts doen we net het tegenovergestelde en proberen we alle variatie te modelleren, waardoor ons model te specifiek is. We spreken in dit geval van overfitting. Een deel van de variatie is namelijk toe te schrijven aan ruis, en als we dit mee gaan modelleren, dan is ons model niet generiek genoeg waardoor we ook slechte voorspellingen zullen maken. Ons model heeft in dit geval te veel parameters.

Bij beslissingsbomen betekent underfitting dat we te weinig vertakkingen hebben, en overfitting dat we er te veel hebben. Denk aan het cocktailvoorbeeld: 2 vertakkingen

was te weinig, underfitting dus, maar het opdelen van de cocktails volgens kleur was ook niet nodig, overfitting dus.

De kunst is dus om een model te vinden dat niet te generiek maar ook niet te specifiek is, waardoor we niet gaan under- of overfitten. Het voorkomen van underfitting is meestal niet zo moeilijk, omdat we dat kunnen oplossen door meer features in rekening te brengen, maar overfitting vermijden is lastiger. In ML zijn er echter verschillende technieken om een goed evenwicht te vinden tussen beide, zoals de dataset uitbreiden, minder features in rekening brengen, regularisatie (bij neurale netwerken worden neuronen bijv kapotgeschoten zodat er minder parameters zijn), of werken met een validatiedataset zodat we de training vroegtijdig kunnen afbreken (= early stopping).

(bronnen: https://docs.aws.amazon.com/machine-learning/latest/dg/model-fit-underfitting-vs-overfitting.html en https://towardsdatascience.com/underfitting-and-overfitting-in-machine-learning-and-how-to-deal-with-it-6fe4a8a49dbf)

Machine learning: overfitting!!!

- Option 1:
  - stop adding nodes to tree when overfitting starts occurring
  - need stopping criterion
- Option 2:
  - don't bother about overfitting when growing the tree
  - after the tree has been built, start pruning it again

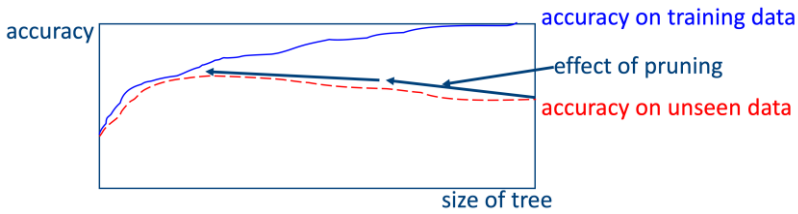

Een (groot) probleem dat kan en zal optreden tijdens het trainen is dus overfitting. Als je een model traint op een dataset, dan wil je eigenlijk dat je model zo veel mogelijk de voorbeelden in de dataset correct voorspelt. In het geval van een beslissingsniveau wil dat zeggen dat je telkens niveaus en criteria blijft toevoegen in de boom tot er geen of quasi geen fouten meer optreden. Maar meestal is dat geen goed idee. Wat je zal zien is, dat indien je je model te specifiek traint op de testdata, dat de accuraatheid van voorspellingen op nieuwe data, zal afnemen. Dit is omdat je teveel toevalligheden die in de data aanwezig zijn, opneemt in je model.

Als je een model traint, moet je er altijd voor zorgen dat er geen te grote kloof komt tussen de accuraatheid op de training-data en de accuraatheid op 'ongeziene' data. Bij een beslissingsboom staan er op de slide twee opties om overfitting tegen te gaan.

Nu, wat is die 'ongeziene' data? Het is geen goed idee om een model te trainen en dan pas te evalueren op overfitting van zodra je het model in productie neemt, want dan pas heb je eigenlijk ongeziene data. Om dit tegen te gaan, wordt de verzameling initiële data in twee delen opgesplitst. Een deel trainingsdata (vaak 80% van de data) en een deel validatiedata (bv. de overige 20% van de data). De validatiedata spelen dan de rol van ongeziene data.

In principe houden we dan ook nog een derde deel van de data achter die we niet gebruiken tijdens het trainen. Dit noemen we de testdata. Deze data gebruiken we

om het model te testen of te evalueren eens het getraind is.
In de testfase gaan we het model toepassen op de testdata en we gaan na of de voorspellingen van ons model goed overeenkomen met de echte waarden. We maken hiervoor gebruik van zogenaamde evaluatiemetrieken. De nauwkeurigheid, d.i. het percentage correcte voorspellingen, is een voorbeeld van een evaluatiemetriek.

Machine learning: overview

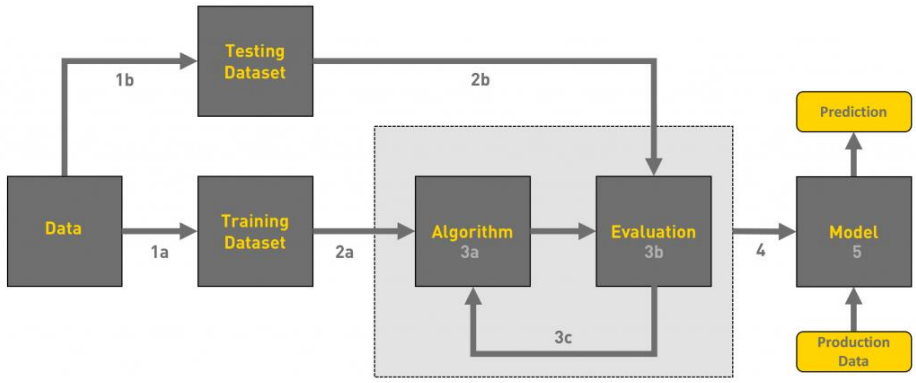

Deze slide vat het trainen van een model bij supervised learning samen, gebruik makend van verschillende datasets.
De trainingsdata worden tijdens het trainen opgesplitst zodat een klein deel kan gebruikt worden voor validatie. De validatie kan overtraining of overfitting aan het licht brengen.
Na de trainingsfase wordt het model geëvalueerd. De test data worden voor deze evaluatie gebruikt.
Indien ook de evaluatie goed is, dan wordt het resulterende model toegepast op productiedata om voorspellingen te maken.

References

- Most slides are adopted from lectures given by prof. Celine Vens and prof. Hendrik Blockeel (Computer Sciences, KUL).
- Some slides are inspired by the first two chapters from the book “grokking Machine Learning (v12)” written by Luis G Serrano.
- Other sources are mentioned on the slides.